



Bài báo

Dự đoán giá cổ phiếu bằng mô hình CNN-BiLSTM-Attention

Cát Lâm Trương¹, Lê Thị Diệp¹ và Yongzeng Lai^{2,*}¹ Khoa Khoa học máy tính và Toán học, Đại học Công nghệ Phúc Kiến, Phúc Châu 350108, Trung Quốc² Khoa Toán học, Đại học Wilfrid Laurier, Waterloo, ON N2L 3C5, Canada * Liên hệ: ylai@wlu.ca

Tóm tắt: Dự đoán giá cổ phiếu chính xác có vai trò quan trọng trong đầu tư cổ phiếu. Vì dữ liệu giá cổ phiếu được đặc trưng bởi tần suất cao, phi tuyến tính và bộ nhớ dài nên việc dự đoán giá cổ phiếu chính xác là một thách thức. Nhiều phương pháp dự báo khác nhau đã được đề xuất, từ các phương pháp chuỗi thời gian cổ điển đến các phương pháp dựa trên máy học, chẳng hạn như rừng ngẫu nhiên (RF), mạng nơ-ron hồi quy (RNN), mạng nơ-ron tích chập (CNN), mạng nơ-ron bộ nhớ dài ngắn hạn (LSTM) và các biến thể của chúng, v.v. Mỗi phương pháp có thể đạt đến một mức độ chính xác nhất định nhưng cũng có những hạn chế. Trong bài báo này, một mô hình dựa trên CNN-BiLSTM-Attention được đề xuất để tăng độ chính xác của việc dự đoán giá cổ phiếu và chỉ số. Đầu tiên, các đặc điểm thời gian của dữ liệu chuỗi được trích xuất bằng mạng nơ-ron tích chập (CNN) và mạng bộ nhớ dài và ngắn hạn hai chiều (BiLSTM). Sau đó, một cơ chế chú ý được giới thiệu để tự động phù hợp với các phép gán trọng số cho các đặc điểm thông tin; và cuối cùng, kết quả dự đoán cuối cùng được đưa ra thông qua lớp dày đặc. Phương pháp được đề xuất lần đầu tiên được sử dụng để dự đoán giá của chỉ số chứng khoán Trung Quốc—chỉ số CSI300 và được xác định là chính xác hơn bất kỳ phương pháp nào trong ba phương pháp còn lại—LSTM, CNN-LSTM, CNN-LSTM-Attention. Để nghiên cứu xem mô hình đề xuất có hiệu quả mạnh mẽ trong việc dự đoán chỉ số chứng khoán hay không, ba chỉ số chứng khoán khác ở Trung Quốc và tám chỉ số chứng khoán quốc tế đã được chọn để thử nghiệm và hiệu quả mạnh mẽ của mô hình CNN-BiLSTM-Attention trong việc dự đoán giá cổ phiếu đã được xác nhận. So sánh phương pháp này với các mô hình LSTM, CNN-LSTM và CNN-LSTM-Attention, có thể thấy độ chính xác của dự đoán giá cổ phiếu là cao nhất khi sử dụng mô hình CNN-BiLSTM-Attention trong hầu hết mọi trường hợp.

Từ khóa: dự đoán giá cổ phiếu; học sâu; CNN; BiLSTM; cơ chế chú ý

MSC: 62-04; 62Pxx

Trích dẫn: Zhang, J.; Vang, L.; Lai, Y.

Dự đoán giá cổ phiếu bằng cách sử dụng

Mô hình chú ý CNN-BiLSTM.

Toán học 2023, 11, 1985. <https://doi.org/10.3390/math11091985>

10.3390/math11091985

Nhận: 5 tháng 3 năm 2023

Đã sửa đổi: 13 tháng 4 năm 2023

Đã chấp nhận: 19 tháng 4 năm 2023

Ngày xuất bản: 23 tháng 4 năm 2023



Bản quyền: © 2023 thuộc về tác giả.

Người được cấp phép MDPI, Basel, Thụy Sĩ.

Bài viết này là một bài viết truy cập mở

được phân phối theo các điều khoản và

điều kiện của Creative Commons

Giấy phép ghi công (CC BY) (<https://creativecommons.org/licenses/by/4.0/>).

1. Giới thiệu

Thị trường chứng khoán là một bộ phận quan trọng của thị trường tài chính, những biến động lớn trên thị trường chứng khoán có thể tác động tiêu cực lớn đến nền kinh tế [1]. Nếu giá cổ phiếu có thể được dự đoán chính xác hơn, có thể tránh được sự sụp đổ của thị trường chứng khoán thông qua các hành động có mục tiêu và có thể định hướng thị trường chứng khoán hoạt động tốt, cuối cùng sẽ đặt nền tảng vững chắc hơn cho sự phát triển lành mạnh của thị trường tài chính [2]. Do đó, việc nghiên cứu giá trị nội tại và dự đoán thị trường chứng khoán đã thu hút ngày càng nhiều sự chú ý của cả học giả và người thực hành, và một loạt các kết quả đã đạt được [3].

Thị trường chứng khoán biến động và không đều, và dữ liệu chứng khoán của thị trường này có những đặc điểm phức tạp như khối lượng dữ liệu lớn, thông tin mơ hồ, phi tuyến tính và không trơn tru. Các phương pháp kinh tế lượng truyền thống như trung bình động hồi quy tự động (ARMA), phương sai dị biệt có điều kiện hồi quy tự động tổng quát (GARCH) và các phương pháp khác có hiệu ứng dự đoán tốt hơn đối với dữ liệu ít biến động [4–6]. Các thuật toán học máy thông thường như Rừng ngẫu nhiên và Máy vectơ hỗ trợ có thể là lựa chọn tốt để tìm hiểu mối quan hệ phi tuyến tính giữa các cổ phiếu và các yếu tố ảnh hưởng khác nhau. Tuy nhiên, các phương pháp này phụ thuộc quá nhiều vào việc lựa chọn mẫu trong quá trình xây dựng mô hình, khiến cho việc xây dựng và cập nhật mô hình trở nên thiếu linh hoạt, dẫn đến

độ chính xác dự đoán gặp khó khăn trong việc đáp ứng các yêu cầu dự báo [7,8]. Các mô hình học sâu có khả năng học tập mạnh mẽ hơn và khả năng tự thích ứng hơn các mô hình máy truyền thống và có thể hoạt động tốt hơn trong phân tích giá cổ phiếu [9].

Mạng nơ-ron bộ nhớ dài hạn ngắn (LSTM) là một loại mạng nơ-ron hồi quy có thể xử lý tốt hơn các chuỗi đầu vào dài trong khi xem xét chuỗi thời gian và bản chất phi tuyến tính của dữ liệu chứng khoán. Do đó, nó được sử dụng rộng rãi trong dự đoán chứng khoán do khả năng bộ nhớ và cấu trúc cổng đặc biệt của nó, so với các mạng nơ-ron hồi quy khác chỉ có thể nhớ các chuỗi ngắn [10]. Moghar và Hamiche đề xuất một mô hình mạng nơ-ron hồi quy (RNN) dựa trên LSTM để dự đoán xu hướng giá mở cửa của GOOGL và NKE, và kết quả thử nghiệm đã xác minh tính hiệu quả của mô hình [11]. Vidal và Kristjanpoller đã đề xuất một CNN và LSTM lai để dự đoán biến động giá vàng và kết luận rằng mô hình có thể trích xuất đầy đủ các tính năng chuỗi thời gian để dự đoán có độ chính xác cao. Kết quả dự đoán tốt hơn so với các mô hình CNN và LSTM riêng lẻ [12]. Nelson và cộng sự sử dụng mạng LSTM để dự đoán xu hướng giá cổ phiếu trong tương lai dựa trên giá lịch sử và các chỉ số phân tích kỹ thuật. Kết quả thử nghiệm cho thấy phương pháp này đạt độ chính xác trung bình là 55,9% [13].

BiLSTM, một Bộ nhớ dài hạn ngắn hạn song hướng, được đề xuất như một phần mở rộng của LSTM đơn hướng truyền thống để cải thiện thêm độ chính xác dự đoán của mô hình với khả năng học các đặc điểm chuỗi thời gian song hướng. Jia và cộng sự sử dụng mô hình BiLSTM để dự đoán giá cổ phiếu GREE và cho thấy BiLSTM đã cải thiện độ chính xác dự đoán so với mô hình LSTM [14]. Wang và cộng sự đề xuất một mô hình CNN-BiLSTM kết hợp, một cải tiến của mô hình BiLSTM, để dự đoán giá cổ phiếu và so sánh nó với mô hình LSTM, mô hình BiLSTM, mô hình CNN-LSTM và mô hình CNN-BiLSTM, và kết luận rằng mô hình được đề xuất là tốt nhất trong số các mô hình này [15].

Cơ chế chú ý trong mạng nơ-ron là một lược đồ phân bổ tài nguyên để phân bổ tài nguyên tính toán cho các tác vụ quan trọng hơn trong khi giải quyết vấn đề quá tải thông tin trong điều kiện năng lực tính toán hạn chế. Cinar và cộng sự đề xuất một mô hình chú ý mở rộng cho RNN. Kết quả thử nghiệm cho thấy mô hình với RNN có thể nắm bắt được chu kỳ giá trong chuỗi thời gian. Hiệu suất mở rộng của nó tốt hơn đáng kể so với bản gốc [16]. Wang và cộng sự đề xuất một mô hình lai dựa trên phân tích bậc hai (SD), phân tích đa yếu tố (MFA) và Bộ nhớ dài hạn dựa trên sự chú ý (ALSTM) để dự đoán xu hướng giá thị trường chứng khoán tại bốn quốc gia châu Á lớn. Kết quả phân tích thực nghiệm cho thấy mô hình đề xuất có thể đạt được độ chính xác cao hơn ít nhất 30% so với Bộ nhớ dài hạn nói chung, chứng minh tính hiệu quả của mô hình lai [17].

Tài liệu liên quan hiện tại hiếm khi xem xét cả vấn đề mà các mô hình dự đoán giá cổ phiếu ngắn hạn LSTM không cho phép kết nối chặt chẽ hơn giữa dữ liệu quá khứ và tương lai cũng như tác động của các đặc điểm cục bộ của dữ liệu cổ phiếu đến độ chính xác dự đoán của các mô hình.

Tóm lại, đóng góp chính của bài báo này là đề xuất một mô hình CNN-BiLSTM-Attention để dự đoán giá cổ phiếu dựa trên những lợi thế về khả năng học các đặc điểm thời gian hai chiều của BiLSTM, giúp cải thiện độ chính xác của dự đoán mô hình và khả năng của cơ chế attention để gán trọng số theo tầm quan trọng của thông tin được sử dụng trong [18-20]. Để minh họa cho tính ưu việt của mô hình được đề xuất so với một số mô hình học sâu thường được sử dụng, chẳng hạn như các mô hình RNN, LSTM, CNN-LSTM, CNN-biLSTM, v.v., mười hai chỉ số thị trường chứng khoán - bốn chỉ số từ Trung Quốc và tám chỉ số từ các thị trường quốc tế - đã được sử dụng làm đối tượng thử nghiệm. Đầu tiên, CNN được sử dụng để trích xuất các đặc điểm cục bộ phi tuyến tính của dữ liệu chứng khoán. Sau đó, BiLSTM được sử dụng để loại bỏ các đặc điểm chuỗi thời gian hai chiều của dữ liệu chuỗi. Cuối cùng, cơ chế attention đã giảm tác động của thông tin dư thừa đến độ chính xác của dự đoán giá cổ phiếu bằng cách gán trọng số lớn hơn cho các thành phần đặc điểm quan trọng hơn thông qua việc tự động khớp các phép gán trọng số với các đặc điểm thông tin được trích xuất bởi lớp BiLSTM. Kết quả thử nghiệm cho thấy mô hình đề xuất có hiệu suất tốt nhất trong số tất cả các mô hình được sử dụng trong dự đoán chỉ số.

Phần còn lại của bài báo được tổ chức như sau. Phần 2 trình bày mô tả về cấu trúc mô hình cho các mạng nơ-ron được sử dụng. Dữ liệu và các chỉ số đánh giá được sử dụng trong thí nghiệm được trình bày trong Phần 3. Phần 4 hiển thị và giải thích kết quả phân tích số. Cuối cùng, Phần 5 kết thúc bài báo.

2. Cấu trúc mô hình 2.1.


Mạng nơ-ron tích chập (CNN)

Mạng nơ-ron tích chập (CNN) được Lecun và cộng sự đề xuất vào năm 1998 [21]. CNN bao gồm năm thành phần chính: lớp đầu vào, lớp tích chập, lớp gộp, lớp kết nối đầy đủ và lớp đầu ra [22]. Lớp tích chập và lớp gộp là trọng tâm của toàn bộ cấu trúc mô hình, chủ yếu được sử dụng để trích xuất các đặc điểm và thực hiện giảm chiều trên các đặc điểm. Với khả năng trích xuất và nhận dạng đặc điểm tuyệt vời, CNN đã được áp dụng thành công trong các tác vụ phân loại dữ liệu hình ảnh và chuỗi thời gian [23]. Nghiên cứu này tập trung vào trích xuất đặc điểm cục bộ phi tuyến tính hiệu quả cho dữ liệu chứng khoán bằng cách sử dụng các lớp tích chập và trích xuất đặc điểm bằng cách sử dụng nén lớp gộp để tạo ra thông tin đặc điểm quan trọng hơn.

2.2. Mạng bộ nhớ dài hạn ngắn hạn (LSTM)

Hochreiter và Schmidhuber lần đầu tiên đề xuất mạng Bộ nhớ dài ngắn hạn (LSTM) vào năm 1997 như một biến thể của Mạng nơ-ron hồi quy (RNN) [10]. So với RNN truyền thống, mạng nơ-ron LSTM thể hiện các đặc điểm phù hợp để xử lý và dự đoán các sự kiện quan trọng với khoảng thời gian dài và độ trễ trong chuỗi thời gian [24]. LSTM cải thiện cấu trúc lớp ẩn của RNN bằng cách giới thiệu một hệ thống các đơn vị gating bao gồm các cổng đầu vào, cổng quên và cổng đầu ra, giúp giảm hiệu quả các vấn đề biến mất gradient và bùng nổ gradient trong quá trình đào tạo mô hình. Cấu trúc được thể hiện trong Hình 1. Trong số đó, cổng quên được sử dụng để quyết định thông tin nào cần loại bỏ khỏi nơ-ron trong mô hình, cổng đầu vào được sử dụng để cập nhật trạng thái đơn vị và cổng đầu ra được sử dụng để điều khiển đầu ra đến thời điểm tiếp theo của nơ-ron [25].

Cấu trúc của ô LSTM được thể hiện trong Hình 1. Trong hình, $h(t-1)$ và h_t lần lượt là đầu ra của ô trước và ô hiện tại. x_t là đầu vào của đơn vị hiện tại, Sigmoid và tanh là các hàm kích hoạt và các vòng tròn trong hình đều chỉ ra các quy tắc số học giữa các vectơ. C_t là trạng thái của nơ-ron tại thời điểm t . f_t là ngưỡng quên, điều khiển cách tế bào loại bỏ thông tin thông qua hàm kích hoạt Sigmoid. Đây là ngưỡng đầu vào xác định thông tin cần được cập nhật bởi hàm Sigmoid, sau đó tạo ra bộ nhớ mới bằng hàm kích hoạt tanh C_t và cuối cùng kiểm soát lượng thông tin mới được thêm vào trạng thái của nơ-ron. O_t là ngưỡng đầu ra, xác định trạng thái nơ-ron đầu ra của hàm Sigmoid và cuối cùng xử lý trạng thái nơ-ron bằng hàm kích hoạt tanh để có được kết quả cuối cùng [26].



Hình 1. Ô nhớ LSTM.

2.3. Mô hình dự báo rủi ro hệ


thông Sơ đồ luồng thuật toán của phương pháp dự báo rủi ro hệ thống hiệu chỉnh lỗi Savgol-TCN được đề xuất trong bài báo này được thể hiện ở Hình 2 và các bước cụ thể như sau.

$$\begin{aligned} f_t &= \sigma[W_f(h_{t-1}, x_t) + b_f], \\ i_t &= \sigma[W_i(x_t, h_{t-1}) + b_i], \\ c_t &= \tanh[W_c(x_t, h_{t-1}) + b_c], \\ U_t &= i_t \odot c_t + f_t \odot c_{t-1}, \\ O_t &= \sigma[W_o(x_t, h_{t-1}) + b_o], \\ h_t &= U_t \odot \tanh(U_t), \end{aligned}$$

trong đó f_t , i_t , và O_t lần lượt là cổng quên, cổng vào và cổng ra; W_f , W_i và W_o lần lượt là các ma trận hệ số trọng số tương ứng với cổng quên, cổng vào và cổng ra; b_f , b_i và b_o biểu thị các hằng số bù tương ứng với cổng quên, cổng vào và cổng ra; U_t là trạng thái của nơ-ron; h_t là đầu ra của lớp ẩn; σ là hàm Sigmoid; và $\odot$ là tích Hadamard.

2.4. Mạng nơ-ron bộ nhớ dài hạn song hướng (BiLSTM)

Mạng nơ-ron Bidirectional Long Short-Term Memory (BiLSTM) là một cải tiến được tối ưu hóa của LSTM [27]. Trong khi LSTM truyền thống dự đoán đầu ra của thời điểm tiếp theo bằng thông tin chuỗi thời gian trong quá khứ, BiLSTM có thể tính đến đầy đủ thông tin trong quá khứ và tương lai bằng cách kết nối một lớp LSTM chuyển tiếp và một lớp LSTM ngược, giúp tạo điều kiện cho cả đầu vào thông tin chuỗi chuyển tiếp và ngược, do đó làm cho mô hình mạnh mẽ hơn [28]. Do đó, bài báo này đã sử dụng mạng nơ-ron BiLSTM để học các đặc điểm tuần tự hai chiều từ thông tin đặc điểm được trích xuất từ lớp CNN, khai thác đầy đủ các đặc điểm phụ thuộc dài hạn của dữ liệu mẫu để học và cuối cùng đưa ra kết quả dự đoán giá cổ phiếu thông qua lớp được liên kết đầy đủ. Cấu trúc BiLSTM được thể hiện trong Hình 2.



Hình 2. Cấu trúc BiLSTM.

Công thức của từng phần trong BiLSTM được đưa ra dưới đây.

$$\begin{aligned} A_i &= f_1(\omega_1 x_i + \omega_2 A_{i-1}), \\ B_i &= f_2(\omega_3 x_i + \omega_4 B_{i+1}), \\ Y_i &= f_3(\omega_5 A_i + \omega_6 B_i), \end{aligned}$$

trong đó f_1 , f_2 và f_3 là các hàm kích hoạt của các lớp tương ứng.

2.5. Cơ chế chú ý

Cơ chế chú ý bắt nguồn từ các nghiên cứu về thị giác của con người. Các mạng nơ-ron truyền thống không thể phân biệt được tầm quan trọng của các tín hiệu trong quá trình xử lý thông tin. Đồng thời, cơ chế chú ý có thể gán các trọng số khác nhau theo các đặc điểm khác nhau, tức là gán trọng số lớn hơn cho thông tin quan trọng và chọn loại bỏ thông tin không quan trọng để cải thiện hiệu quả xử lý thông tin thông qua việc gán trọng số khác biệt và giải quyết vấn đề mất thông tin do các chuỗi dài trong LSTM. Do đó, việc đưa cơ chế chú ý vào có thể cải thiện thêm độ chính xác của dự đoán giá cổ phiếu.


2.6. Thành phần mô hình dự đoán sự chú ý CNN-BiLSTM

Như đã chỉ ra trước đó, việc dự báo giá cổ phiếu (hoặc tài sản khác) rất quan trọng đến nỗi các học giả đã cố gắng sử dụng nhiều phương pháp khác nhau cho mục đích đó. Có rất nhiều chỗ để nâng cao độ chính xác của dự đoán, đặc biệt là với sự trợ giúp của sự phát triển mới trong công nghệ. Bài báo này đề xuất một phương pháp dự đoán giá đóng cửa cổ phiếu dựa trên mô hình CNN-BiLSTM-Attention. Quá trình của phương pháp này có thể được mô tả như sau.

Bước 1: Dữ liệu kho được thu thập được chuẩn hóa và chia thành đào tạo và thử nghiệm mức độ.

Bước 2: Đầu tiên, lớp CNN được sử dụng để trích xuất các đặc điểm bên trong của dữ liệu chứng khoán và lớp CNN bao gồm một lớp tích chập 2D, một lớp gộp và một lớp bỏ qua. Sau đó, lớp BiLSTM được đào tạo trên các đặc điểm cục bộ được CNN trích xuất để tìm hiểu mẫu thay đổi động bên trong. Một cơ chế chú ý được giới thiệu để tự động gán các trọng số khác nhau cho các đặc điểm được lớp BiLSTM trích xuất để khám phá mối tương quan thời gian sâu. Cuối cùng, đầu ra được truyền qua một lớp dày đặc. Sơ đồ cấu trúc mạng của nó được hiển thị trong Hình 3.

Bước 3: Kết quả dự đoán được chuẩn hóa để có được giá trị mong muốn.



Hình 3. Mạng nơ-ron CNN-BiLSTM-Attention.

Bài báo này sử dụng phần mềm Paycharm để xây dựng mô hình CNN-BiLSTM-Attention. Hàm kích hoạt được sử dụng là ReLU. Hàm mất mát được sử dụng là hàm MSE (Mean_squared_error). Bộ tối ưu hóa được sử dụng là thuật toán tối ưu hóa Adam phổ biến để cập nhật các tham số của từng lớp của mạng. Lớp Dropout liên quan đã giúp ngăn ngừa sự xuất hiện của quá khớp, cải thiện khả năng khái quát hóa của mô hình và giảm thời gian đào tạo cho mô hình. Để xác minh hiệu quả của mô hình, mô hình được xây dựng cũng được so sánh với các mô hình LSTM, CNN-LSTM và CNN-LSTM-Attention về hiệu suất dự đoán trong bài báo này.

3. Thí nghiệm

3.1. Mô tả dữ liệu

Bài báo này đã chọn dữ liệu của Chỉ số CSI 300 từ ngày 4 tháng 1 năm 2011 đến ngày 31 tháng 12 năm 2021, tổng cộng 2675 ngày giao dịch để dự đoán giá cổ phiếu và dự đoán giá đóng cửa. Chỉ số Shanghai Shenzhen CSI 300 là một trong những chỉ số thị trường chứng khoán được theo dõi chặt chẽ nhất của Trung Quốc. Chỉ số này bao gồm 300 cổ phiếu A-share được giao dịch trên sàn giao dịch chứng khoán Thượng Hải và Thâm Quyển và được coi là chỉ báo về xu hướng ở cả hai thị trường đó. Các tính năng được chọn bao gồm giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa, khối lượng, doanh thu và lợi nhuận. Một chiến lược dự đoán trực tiếp một bước đã được sử dụng. Tỷ lệ dữ liệu được sử dụng cho tập huấn luyện, tập kiểm tra và tập xác thực là 6:2:2.

3.2. Tiền xử lý dữ liệu

Có một thang đo lớn giữa dữ liệu đặc điểm trong bài báo này. Để loại bỏ ảnh hưởng của thang đo giữa các đặc điểm, tập dữ liệu đã được chuẩn hóa trong bài báo này. Quá trình chuẩn hóa hữu ích để tăng tốc độ hội tụ của hàm mất mát, ngăn chặn sự bùng nổ gradient trong quá trình đào tạo mạng và cải thiện độ chính xác tính toán. Trong bài báo này, dữ liệu đã được chuẩn hóa thành $[0, 1]$ bằng cách sử dụng chuẩn hóa Min-Max và quá trình tính toán được thể hiện trong Phương trình (1).

$$x_{\text{min}} = \frac{x_i - x_{\text{min}}}{x_{\text{max}} - x_{\text{min}}}, \quad (1)$$

trong đó x_i là dữ liệu gốc, x là giá trị chuẩn hóa, x_{min} và x_{max} lần lượt là giá trị nhỏ nhất và lớn nhất của dữ liệu gốc. Vì dữ liệu được chuẩn hóa bởi mô hình cũng được chuẩn hóa, nên dữ liệu đầu ra được phi chuẩn hóa bởi quy trình flip-flop. Công thức tính toán được thể hiện trong (2).

$$x = (x_{\text{max}} - x_{\text{min}}) \cdot y + x_{\text{min}}, \quad (2)$$

trong đó y là dự báo giá cổ phiếu được chuẩn hóa. x là giá trị dự báo giá cổ phiếu thực tế thu được sau khi chuẩn hóa.

3.3. Các chỉ số đánh giá

Bài báo này sử dụng ba chỉ số đánh giá, Sai số phần trăm tuyệt đối trung bình (MAPE), để đánh giá mô hình Sai số bình phương trung bình căn bậc hai (RMSE) và hệ số xác định hiệu suất dự đoán R^2 . Chúng được tính theo các phương trình (3), (4) và (5) tương ứng.

$$\text{BẢN ĐỒ} = \frac{1}{n} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\%, \quad (3)$$


$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}, \quad (4)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}, \quad (5)$$


2

[illegible]


So sánh với kết quả dự đoán của ba mô hình khác, có thể thấy rằng mô hình CNN-BiLSTM-Attention có độ chính xác việc dự đoán trạng thái của dự đoán về các đoạn văn bản. Các thí nghiệm khác nhau đã được thực hiện để đánh giá hiệu suất của mô hình. Kết quả cho thấy rằng mô hình có thể xử lý các đoạn văn bản dài và phức tạp. Các thí nghiệm khác nhau đã được thực hiện để đánh giá hiệu suất của mô hình. Kết quả cho thấy rằng mô hình có thể xử lý các đoạn văn bản dài và phức tạp.




Hình 4. Hình ảnh kết quả dự đoán dựa trên LSTM.



Hình 5. Kết quả dự đoán dựa trên CNN-LSTM.



Hình 6. Kết quả dự đoán dựa trên CNN-LSTM-Attention.



Hình 7. Kết quả dự đoán dựa trên CNN-BiLSTM-Attention.

Những so sánh trên với các con số rất trực quan nhưng cũng khá thô sơ. định lượng sự so sánh các kết quả dự đoán, các giá trị của ba số lượng được tính toán theo Phương trình (3)-(5) cho bốn mô hình có chỉ số được thể hiện trong Bảng 1, trong đó kết quả tốt nhất trong các mô hình là in đậm (tương tự đối với các bảng khác).

Bảng 1. So sánh các chỉ số lỗi đánh giá của bốn phương pháp.

Phương pháp	MẠNG LƯỢNG (%)	RMSE	R ²
LSTM	1.877	108.748	0,958
CNN-LSTM CNN-	1.482	89.048	0,972
LSTM-Chú ý.	1.288	76.454	0,979
CNN-BiLSTM-Chú ý	1.023	64.848	0,985

Các con số in đậm chỉ ra kết quả tốt nhất trong số các mô hình.


Từ Bảng 1, có thể thấy rằng độ chính xác dự đoán được sắp xếp từ cao đến thấp là mô hình CNN-BiLSTM-Attention, mô hình CNN-LSTM-Attention, mô hình CNN-LSTM và Mô hình LSTM, tương ứng. RMSE của mô hình CNN-BiLSTM-Attention để dự đoán giá đóng cửa của Chỉ số CSI 300 là 64,84, thấp hơn LSTM đơn lẻ, CNN-LSTM, và CNN-LSTM-Attention lần lượt là 43,9, 24,2 và 11,606. Về MAPE, Mô hình CNN-BiLSTM-Attention, so sánh với mô hình LSTM, mô hình CNN-LSTM và Mô hình CNN-LSTM-Attention, giảm lần lượt 0,854%, 0,459% và 0,265%, tiếp tục xác minh định lượng tính hợp lý và hiệu quả của CNN-LSTM-Attention mô hình được đề xuất trong bài báo này.

5. Mô hình phân tích mạnh mẽ

Để xác minh thêm độ chính xác và độ tin cậy của mô hình được đề xuất trong bài báo này, mô hình CNN-BiLSTM-Attention và ba mô hình khác sẽ được sử dụng để dự đoán giá đóng cửa của các chỉ số chứng khoán Trung Quốc và quốc tế để có được các lỗi thử nghiệm. Chỉ số Trung Quốc được chọn là chỉ số cổ phiếu SSE A, chỉ số tổng hợp SSE và SZSI chỉ số thành phần và chỉ số quốc tế được chọn là AEX (Sàn giao dịch chứng khoán Amsterdam) chỉ số), ATX (Chỉ số giao dịch của Á o), FCHI (Chỉ số CAC 40), FTSE (Financial Times Stock Chỉ số Exchange 100), HSI (Chỉ số Hang Seng), JKSE (Sàn giao dịch chứng khoán Jakarta), KLSE (Kuala Sàn giao dịch chứng khoán Kuala Lumpur) và OEX (S&P 100).

5.1. Mô hình phân tích mạnh mẽ dựa trên chỉ số thị trường Trung Quốc


Dữ liệu được chọn để dự đoán giá cổ phiếu từ ngày 4 tháng 1 năm 2011 đến ngày 31 tháng 12 năm 2021 (vào thời điểm dự án bắt đầu), tổng cộng là 2675 ngày giao dịch; xu hướng giá đóng cửa của các chỉ số chứng khoán được thể hiện ở Hình 8.




Hình 8. Xu hướng của chỉ số chứng khoán Trung Quốc.

Biểu đồ cho thấy bốn chỉ số chứng khoán được chọn nhìn chung có xu hướng tương tự nhau, đặc biệt là Chỉ số cổ phiếu SSE A, Chỉ số tổng hợp SSE và Chỉ số CSI 300. Việc chuẩn hóa sẽ loại bỏ hiệu ứng của độ lớn và các siêu tham số được sử dụng trong dự đoán sẽ không thay đổi.


Để tiết kiệm không gian, việc so sánh dự đoán của từng chỉ số được đề cập ở trên theo bốn mô hình đã chọn được thể hiện trong một hình. Ý nghĩa tương tự như giải thích ở trên—đường cong của mô hình càng gần với đường cong thực tế thì mô hình càng tốt. Kết quả dự đoán được thể hiện trong Hình 9–11. Có thể thấy rằng mô hình CNN-BiLSTM-Attention có khả năng khái quát hóa tốt và độ tin cậy tốt. Tuy nhiên, độ chính xác dự đoán cục bộ của mô hình giảm ở các điểm đột biến trong giá cổ phiếu.



Hình 9. So sánh kết quả dự đoán Chỉ số cổ phiếu A của SSE.



Hình 10. So sánh kết quả dự đoán của Chỉ số tổng hợp SSE.



Hình 11. So sánh kết quả dự đoán Chỉ số cổ phiếu thành phần A của SZSE.

Một lần nữa, các so sánh trên với các con số rất trực quan nhưng khá thô sơ. Để định lượng sự so sánh các kết quả dự đoán, các giá trị của ba số lượng được tính toán bằng Phương trình (3)-(5) cho bốn mô hình với mỗi chỉ số được thể hiện trong Bảng 2.

Bảng 2. So sánh các chỉ số lỗi đánh giá của bốn phương pháp trong ba chỉ số.

Mục lục		LSTM CNN-LSTM		CNN-LSTM- Chú ý	CNN- BiLSTM- Chú ý
Đồng Nam Á	BẢN ĐỒ	1,136	0,943	0,914	0,836
	A-chia sẻ	RMSE	50,859	41,988	39.750
	Mục lục	R ²	0,970	0,979	0,982
Hợp chất	BẢN ĐỒ	0,968	0,995	0,874	0,851
	RMSE	42,737	41,600	40,360	37.988
	Mục lục	R	0,977	0,978	0,979
SZSE	BẢN ĐỒ	1.429	1,185	1.565	1.160
	RMSE	291.072	251.561	315.153	251.095
	Chỉ số A-Share	R	0,985	0,989	0,989


Các con số in đậm chỉ ra kết quả tốt nhất trong số các mô hình.

Bảng 2 cho thấy mô hình CNN-BiLSTM-Attention vượt trội hơn các mô hình khác trong dự đoán giá đóng cửa của Chỉ số cổ phiếu A của SSE, Chỉ số tổng hợp SSE và Chỉ số cổ phiếu thành phần A của SZSE. Phân tích kết quả dự đoán chỉ số cổ phiếu A của SSE cho thấy giá trị RMSE của mô hình CNN-BiLSTM-Attention thấp hơn 7,13% so với của mô hình tốt thứ hai, CNN-LSTM-Attention, và R² giá trị cũng đã được cải thiện. phân tích kết quả dự đoán cho Chỉ số tổng hợp SSE cho thấy mô hình CNN-BiLSTM-Attention có giá trị RMSE thấp hơn 5,88% và R² được cải thiện giá trị so sánh với mô hình CNN-LSTM-Attention. Phân tích kết quả dự đoán của SZSE chỉ số A-share thành phần cho thấy giá trị RMSE của CNN-BiLSTM-Attention mô hình thấp hơn 20,3% so với mô hình tốt thứ hai, CNN-LSTM-Attention và R² giá trị được cải thiện từ 0,982 lên 0,989, điều này cho thấy độ chính xác dự đoán của mô hình đã được cải thiện. Trong khi đó, người ta có thể thấy từ Bảng 2 rằng MAPE và R² của ba chỉ số tương tự nhau. Tuy nhiên, RMSE của Chỉ số cổ phiếu A của SSE và Chỉ số tổng hợp của SSE thấp hơn nhiều so với Chỉ số cổ phiếu thành phần A của SZSE do sự khác biệt trong phác thảo dữ liệu gốc và lỗi bình phương trung bình sẽ khác nhau.


5.2. Mô hình phân tích mạnh mẽ dựa trên chỉ số thị trường quốc tế

Tám chỉ số quốc tế, cụ thể là AEX, ATX, FCHI, FTSE, HSI, JKSE, KLSE và OEX đã được chọn để dự báo giá đóng cửa của họ và đưa ra lỗi kiểm tra bằng cách chọn đặc điểm bao gồm giá mở cửa, giá cao, giá thấp, giá đóng cửa, khối lượng và trả về. Dữ liệu giao dịch từ ngày 3 tháng 1 năm 2011 đến ngày 29 tháng 10 năm 2021 được chọn. Dữ liệu đầu tiên được chuẩn hóa để loại bỏ hiệu ứng của thể tích và các siêu tham số được sử dụng cho dự báo không thay đổi.


Sự so sánh kết quả dự đoán của các chỉ số này được thể hiện trong Hình 12-19, trong đó ý nghĩa của mỗi hình có thể được giải thích tương tự như những hình trước đó. Đường cong của kết quả dự đoán của mô hình CNN-BiLSTM-Attention gần nhất với đường cong của dữ liệu thực tế nói chung. Nghĩa là, mô hình CNN-BiLSTM-Attention là chính xác nhất trong bốn mô hình này. So với kết quả dự báo của các chỉ số Trung Quốc, các chỉ số quốc tế có nhiều dự báo chậm trễ hơn, có lẽ liên quan đến “T+1” hệ thống giao dịch tại Trung Quốc và hệ thống “T+0” trên thị trường quốc tế.




Hình 12. So sánh kết quả dự đoán của Chỉ số AEX.




Hình 13. So sánh kết quả dự đoán Chỉ số ATX.




Hình 14. So sánh kết quả dự đoán Chỉ số FCHI.




Hình 15. So sánh kết quả dự đoán của Chỉ số FTSE.




Hình 16. So sánh kết quả dự đoán Chỉ số HSI.



Hình 17. So sánh kết quả dự đoán của Chỉ số JKSE.



Hình 18. So sánh kết quả dự đoán Chỉ số KLSE.



Hình 19. So sánh kết quả dự đoán của Chỉ số OEX.

Một lần nữa, những so sánh trên với các con số rất trực quan nhưng cũng khá thô. Để định lượng sự so sánh các kết quả dự đoán, các giá trị của ba số lượng được tính toán bằng Phương trình (3)–(5) cho bốn mô hình với mỗi chỉ số được thể hiện trong Bảng 3.

Bảng 3 cho thấy mô hình CNN-BiLSTM-Attention vượt trội hơn các mô hình LSTM, CNN-LSTM và CNN-LSTM-Attention trong việc dự đoán giá chỉ số chứng khoán, với giá trị nhỏ nhất lỗi phần trăm tuyệt đối trung bình và lỗi bình phương trung bình căn bậc hai và hệ số xác định gần nhất với 1. Phân tích kết quả dự đoán AEX cho thấy giá trị RMSE của mô hình CNN-BiLSTM-Attention thấp hơn 7,6% so với giá trị thứ hai và dự đoán ATX cho thấy giá trị RMSE của mô hình CNN-BiLSTM-Attention thấp hơn 7,6% so với giá trị thứ hai. Giá trị RMSE của mô hình CNN-BiLSTM-Attention thấp hơn 7,6% so với giá trị thứ hai; giá trị RMSE của mô hình ATX thấp hơn giá trị thứ hai 5,9%; giá trị RMSE của mô hình FCHI thấp hơn 5,9% so với giá trị thứ hai; và RMSE giá trị của mô hình CNN-BiLSTM-Attention thấp hơn 7,6% so với giá trị thứ hai. Là một

2 kết quả, giá trị RMSE thấp hơn 32,8% so với giá trị thứ hai và R

giá trị tăng lên

từ 0,967 đến 0,985; phân tích kết quả dự đoán FTSE cho thấy giá trị RMSE của mô hình CNN-BiLSTM-Attention thấp hơn 10,7% so với giá trị thứ hai; nghiên cứu về kết quả dự đoán cho thấy giá trị RMSE của mô hình CNN-BiLSTM-Attention thấp hơn 3,3% so với giá trị thứ hai; phân tích kết quả dự đoán của JKSE cho thấy

rằng giá trị RMSE của mô hình CNN-BiLSTM-Attention thấp hơn 16,3% so với giá trị thứ hai giá trị; nghiên cứu kết quả dự đoán KLSE cho thấy giá trị RMSE của mô hình CNN-BiLSTM-Attention thấp hơn 1,3% so với giá trị thứ hai; và phân tích OEX kết quả dự đoán cho thấy giá trị RMSE của CNN-BiLSTM-Attention giảm 2,7% mô hình so với giá trị tiếp theo. Điều này chỉ ra rằng độ chính xác dự đoán của mô hình đã được cải thiện.

Bảng 3. So sánh sai số của kết quả dự báo chỉ số chứng khoán quốc tế

bằng nhiều mô hình khác nhau.

Mục lục		LSTM	CNN-LSTM	CNN-LSTM-Chú ý	CNN-BiLSTM-Chú ý
AEX	BẢN ĐỒ	2.216	7.548	1.473	1.360
	RMSE	16.789	60.953	11.958	11.733
	R	0,963	0,516	0,981	0,982
ATX	BẢN ĐỒ	1.617	1.368	1.350	1.282
	RMSE	58.111	54.533	51.087	48.055
	R	0,989	0,991	0,991	0,992
FCHI	BẢN ĐỒ	1.866	2.873	2.186	1.112
	RMSE	131.868	265.854	162.568	88.527
	R	0,967	0,866	0,950	0,985
FTSE	BẢN ĐỒ	1.238	1.163	1.075	0,914
	RMSE	97.471	93.177	86.936	77.576
	R ²	0,965	0,968	0,972	0,978
HSI	BẢN ĐỒ	1.609	1.431	1.682	1.404
	RMSE	519.059	498.572	543.748	481.974
	R	0,912	0,919	0,903	0,924
Trưởng JKSE	BẢN ĐỒ	1.552	1.380	1.807	1.141
	RMSE	110.962	101.035	146.146	84.538
	R	0,976	0,980	0,958	0,986
KLSE	BẢN ĐỒ	0,953	0,929	0,864	0,898
	RMSE	20.043	20.453	20.477	19.782
	R	0,940	0,937	0,937	0,941
OEX	BẢN ĐỒ	2.873	6.217	1.587	1.501
	RMSE	57.432	130.388	33.193	32.278
	R ²	0,947	0,726	0,982	0,983

Các con số in đậm chỉ ra kết quả tốt nhất trong số các mô hình.

6. Kết luận và công việc tương lai

Dự báo giá tài sản (như cổ phiếu) rất quan trọng trong các hoạt động đầu tư tài chính . Dự đoán chính xác là một thách thức do tính phức tạp của vấn đề. Do đó, các phương pháp và công nghệ tiên tiến nhất hiện có được sử dụng để dự đoán giá tài sản, từ RNN, LSTM, CNN-LSTM, biLSTM, CNN-biLSTM, v.v. Quá trình này sẽ tiếp tục khi các phương pháp hoặc công nghệ mới xuất hiện. Để cải thiện độ chính xác của giá cổ phiếu dự đoán, sự kết hợp của CNN-BiLSTM và cơ chế chú ý, tức là, Mô hình CNN-BiLSTM-Attention được đề xuất để dự đoán giá trong bài báo này đầu tiên sử dụng dữ liệu chỉ số CSI 300. Kết quả thử nghiệm cho thấy mô hình CNN-BiLSTM-Attention đạt được độ chính xác tốt nhất trong dự đoán chỉ số giá cổ phiếu trong bốn mô hình-LSTM, CNN-LSTM, CNN-LAST-Attention và CNN-BiLSTM-Attention. Để tiến hành mô hình phân tích tính ổn định của mô hình đề xuất, bốn mô hình trên đã được sử dụng để dự đoán cổ phiếu giá hoặc chỉ số sử dụng 12 dữ liệu chỉ số thị trường chứng khoán được chọn từ Trung Quốc và nước ngoài. Một lần nữa, kết quả thử nghiệm cho thấy mô hình đề xuất có thể dự đoán hiệu quả các chỉ số chứng khoán của thị trường chứng khoán ở Trung Quốc và các nước khác, cho thấy mô hình đề xuất có mức độ khái quát nhất định. Tuy nhiên, chỉ số đánh giá được sử dụng trong bài báo này là dữ liệu giao dịch chứng khoán và có nhiều yếu tố ảnh hưởng đến giá cổ phiếu hoặc chỉ số trong tài chính

thị trường. Vì vậy, giống như các mô hình khác, mô hình được đề xuất cũng có những hạn chế, chủ yếu là do cấu trúc mô hình. Để cải thiện độ chính xác của dự đoán, có thể thực hiện nhiều công việc hơn, chẳng hạn như tích hợp thông tin không đồng nhất từ nhiều nguồn cổ phiếu vào chỉ số hoặc kết hợp các mô hình mới nhất hoặc thậm chí phát triển các mô hình mới, tất nhiên là rất khó. Do hạn chế về thời gian và không gian, các tác giả đã không thực hiện thử nghiệm các phương pháp được sử dụng trong nghiên cứu này với dữ liệu ở các thị trường Bắc Mỹ, mặc dù người ta tin rằng có thể thu được kết luận tương tự. Tất cả những điều này có thể được xem xét trong các công trình trong tương lai.

Đóng góp của tác giả: Phương pháp luận, YL; Phần mềm, LY; Xác thực, LY; Phân tích chính thức, YL; Điều tra, JZ và LY; Quản lý dữ liệu, LY; Viết-bản thảo gốc, LY; Viết-đánh giá và biên tập, YL; Giám sát, JZ; Quản lý dự án, JZ và YL; Thu hút tài trợ, JZ và YL

Tất cả các tác giả đã đọc và đồng ý với phiên bản thảo đã xuất bản.

Nguồn tài trợ: Nghiên cứu này được hỗ trợ bởi Hội đồng nghiên cứu khoa học tự nhiên và kỹ thuật (NSERC) của Canada (RGPIN-2019-05906) và Quỹ khoa học quốc gia của tỉnh Phúc Kiến (Số: 2020J01892).

Tuyên bố về tính khả dụng của dữ liệu: Dữ liệu được sử dụng trong bài báo có thể được cung cấp theo yêu cầu.

Lời cảm ơn: Các tác giả rất biết ơn Biên tập viên và ba Người đánh giá ẩn danh vì sự giúp đỡ, những gợi ý có giá trị và những bình luận.

Xung đột lợi ích: Các tác giả tuyên bố không có xung đột lợi ích.

Tài liệu tham khảo

1. Yu, W.; Peng, W. Dự báo biến động của ssec trên thị trường chứng khoán Trung Quốc bằng cách sử dụng phân tích đa phân số. *Phys. Stat. Mech. Appl.* **2008**, *387*, 1585–1592.
2. Wang, P.; Lou, Y.; Lei, L. Nghiên cứu về Dự đoán giá cổ phiếu dựa trên Mạng nơ-ron BP Wavelet với Cơ sở Mexico Hat Wavelet. Trong *Biên bản báo cáo Hội nghị quốc tế năm 2017 về Nghiên cứu giáo dục, kinh tế và quản lý (ICEEMR 2017)*, Singapore, 29–31 tháng 5 năm 2017; trang 99–102.
3. Hao, Y.; Gao, Q. Dự đoán xu hướng của chỉ số thị trường chứng khoán bằng mạng nơ-ron lai dựa trên tính năng thang thời gian đa học tập. *Khoa học ứng dụng.* **2020**, *10*, 3961.
4. Dwivedi, SA; Attry, A.; Parekh, D.; Singla, K. Phân tích và dự báo dữ liệu chuỗi thời gian sử dụng S-ARIMA, CNN và LSTM. Trong *Biên bản báo cáo Hội nghị quốc tế năm 2021 về máy tính, truyền thông và hệ thống thông minh (ICCCIS)*, Greater Noida, Ấn Độ, 19–20 tháng 2 năm 2021; trang 131–136.
5. Parmar, K.; Singh, S.; Kumar, J. Các mô hình tính toán mềm kết hợp với các mô hình thống kê ước tính tương lai của thị trường chứng khoán. *Neural Comput. Appl.* **2021**, *33*, 7629–7647.
6. Xiang, Y. Sử dụng mô hình ARIMA-GARCH để phân tích quy luật biến động của giá dầu quốc tế. *Toán. Xác suất. Kỹ thuật.* **2022**, *2022*, 3936414. <https://doi.org/10.1155/2022/3936414>.
7. Ince, H.; Trafalis, TB Phân tích thành phần chính của hạt nhân và máy vectơ hỗ trợ để dự đoán giá cổ phiếu. Trong *Biên bản báo cáo của Hội nghị chung quốc tế IEEE năm 2004 về mạng nơ-ron*, Budapest, Hungary, 25–29 tháng 7 năm 2004; IEEE Cat. No. 04CH37541; Tập 3, trang 2053–2058. [\[CrossRef\]](#)
8. Yin, L.; Li, B.; Li, P.; Zhang, R. Nghiên cứu về phương pháp dự đoán xu hướng cổ phiếu dựa trên rừng ngẫu nhiên tối ưu. *CAAI Trans. Intell. Công nghệ.* **2021**, *8*, 274–284. <https://doi.org/10.1049/cit2.12067>.
9. Sun, L.; Xu, W.; Liu, J. Mô hình hợp nhất cơ chế chú ý hai kênh để dự đoán giá cổ phiếu dựa trên cnn-lstm. *ACM Trans. Quy trình thông tin ngôn ngữ - Tài nguyên thấp của Châu Á.* **2021**, *20*, 1–12.
10. Hochreiter, S.; Schmidhuber, J. Bộ nhớ dài hạn ngắn hạn. *Máy tính thần kinh.* **1997**, *9*, 1735–1780.
11. Moghar, A.; Hamiche, M. Dự đoán thị trường chứng khoán bằng mạng nơ-ron hồi quy LSTM. *Procedia Comput. Sci.* **2020**, *170*, 1168–1173. [\[Tham khảo chéo\]](#)
12. Vidal, A.; Kristjanpoller, W. Dự đoán biến động vàng bằng CNN-LSTM. *Expert Syst. Appl.* **2020**, *157*, 113481.
13. Nelson, D.; Pereira, A.; Oliveira, R. Dự đoán biến động giá của thị trường chứng khoán bằng mạng nơ-ron LSTM. Trong *Biên bản báo cáo Hội nghị chung quốc tế về mạng nơ-ron năm 2017 (IJCNN)*, Anchorage, AL, Hoa Kỳ, 14–19 tháng 5 năm 2017; IEEE: New York, NY, Hoa Kỳ, 2017; tr. 1419. [\[CrossRef\]](#)
14. Jia, M.; Huang, J.; Pang, L.; Zhao, Q. Phân tích và nghiên cứu về giá cổ phiếu của LSTM và mạng nơ-ron LSTM hai chiều. Trong *Biên bản Hội nghị quốc tế lần thứ 3 về Kỹ thuật máy tính, Khoa học thông tin và Công nghệ ứng dụng (ICCIA 2019)*, Trùng Khánh, Trung Quốc, ngày 30–31 tháng 5 năm 2019; trang 467–473. [\[CrossRef\]](#)
15. Wang, H.; Wang, J.; Cao, L.; Li, Y.; Sun, Q.; Wang, J. Một mô hình dự đoán giá đóng cửa cổ phiếu dựa trên CNN-biLSTM. *Độ phức tạp* **2021**, *2021*, 5360828. [\[Tham chiếu chéo\]](#) [\[PubMed\]](#)

16. Cinar, YG; Mirisaee, H.; Goswami, P.; Gaussier, E.; Strijov, V. Sự chú ý nội dung dựa trên vị trí để dự báo chuỗi thời gian với RNN chuỗi-sang-chuỗi. Trong Xử lý thông tin thần kinh: Hội nghị quốc tế lần thứ 24, ICONIP 2017, Quảng Châu, Trung Quốc, 14-18 tháng 11 năm 2017; Springer: Berlin/Heidelberg, Đức, 2017; tr. 533-544. [\[CrossRef\]](#)
17. Wang, J.; Cui, Q.; Sun, X.; He, M. Dự báo chỉ số đóng cửa của thị trường chứng khoán châu Á dựa trên phân tích thứ cấp, phân tích đa yếu tố và mô hình LSTM dựa trên sự chú ý. Eng. Appl. Artif. Intell. 2022, 113, 104908. [\[CrossRef\]](#)
18. Chen, Y.; Fang, R.; Liang, T.; Sha, Z.; Li, S.; Yi, Y.; Zhou, W.; Song, H. Dự báo giá cổ phiếu dựa trên mô hình CNN-BiLSTM-ECA. Sci. Chương trình. 2021, 2021, 2446543. <https://doi.org/10.1155/2021/2446543>.
19. Lu, W.; Li, J.; Wang, J.; Qin, L. Một phương pháp CNN-BiLSTM-AM để dự đoán giá cổ phiếu. Neural Comput. Appl. 2020, 33, 4741-4753.
20. Zhao, H.; Xue, L. Nghiên cứu về dự báo cổ phiếu dựa trên mô hình LSTM-CNN-CBAM. Comput. Eng. Appl. 2021, 57, 203-207.
21. Lecun, Y.; Botou, L.; Bengio, Y.; Haffner, P. Học tập dựa trên độ dốc được áp dụng vào nhận dạng tài liệu. IEEE Proc. 1998, 86, 2278-2324. [\[Tham chiếu chéo\]](#)
22. Luo, J.; Zhang, X. Mạng nơ-ron tích chập dựa trên cơ chế chú ý và bi-lstm để dự đoán tuổi thọ còn lại. Appl. Intell. Int. J. Artif. Intell. Neural Netw. Complex-Probl.-Solving Technol. 2022, 52, 1076-1091. [\[CrossRef\]](#)
23. Selvin, S.; Vijayakumar, R.; Gopalakrishnan, EA; Menon, VK; Soman, KP Dự đoán giá cổ phiếu bằng mô hình LSTM, RNN và CNN-sliding window. Trong Biên bản báo cáo Hội nghị quốc tế về những tiến bộ trong truyền thông máy tính và tin học (ICACCI), Manipal, Ấn Độ, 13-16 tháng 9 năm 2017; IEEE: New York, NY, Hoa Kỳ, 2017; tr. 1643-1647.
24. Wu, Q.; Guan, F.; Lv, C.; Huang, Y. Dự báo năng lượng gió nhiều bước cực ngắn hạn dựa trên cnn-lstm. IET Renew. Power Tháng Giêng. 2021, 15, 1019-1029.
25. Sun, Y.; Sun, Q.; Zhu, S. Dự đoán chỉ số chứng khoán Thượng Hải dựa trên tâm lý nhà đầu tư và mô hình cnn-lstm. J. Syst. Sci. Inf. Công nghệ. Anh. Ed. 2022, 10, 620-632.
26. Lu, W.; Li, J.; Li, Y.; Sun, A.; Wang, J. Một mô hình dựa trên cnn-lstm để dự báo giá cổ phiếu. Độ phức tạp 2020, 2020, 1-10.
27. Xu, Y.; Prince, H.; Wu, Z. Dự đoán xu hướng cổ phiếu bằng mô hình tích hợp đa tính năng dựa trên CNN-Bi LSTM. Phân tích dữ liệu. Kiến trúc. Nhạc disco. 2021, 7, 126-137.
28. Eapen, J.; Bein, D.; Verma, A. Mô hình học sâu mới với CNN và LSTM hai chiều để cải thiện dự đoán chỉ số thị trường chứng khoán. Trong Biên bản báo cáo Hội thảo và Hội nghị về máy tính và truyền thông thường niên lần thứ 9 của IEEE (CCWC), Las Vegas, NV, Hoa Kỳ, 7-9 tháng 1 năm 2019; IEEE: New York, NY, Hoa Kỳ, 2019; trang 264-270.

Tuyên bố miễn trừ trách nhiệm/Ghi chú của Nhà xuất bản: Các tuyên bố, ý kiến và dữ liệu có trong tất cả các ấn phẩm chỉ là của cá nhân tác giả và người đóng góp chứ không phải của MDPI và/hoặc biên tập viên. MDPI và/hoặc biên tập viên từ chối trách nhiệm đối với bất kỳ thương tích nào đối với người hoặc tài sản phát sinh từ bất kỳ ý tưởng, phương pháp, hướng dẫn hoặc sản phẩm nào được đề cập trong nội dung.